

Projekt 12: Ocena ryzyka deszczu i krótkoterminowa predykcja

Kornel Wasilewski
Maciej Truchanowski

1 Cel projektu

Celem projektu jest oszacowanie krótkoterminowego ryzyka deszczu na podstawie ostatnich pomiarów pogodowych pobranych ze współdzielonego Weather REST API. System przetwarza dane pogodowe, tworzy cechy kroczące, oblicza wynik ryzyka deszczu w skali od 0 do 100 oraz przewiduje, czy deszcz wystąpi w kolejnym pomiarze.

Projekt skupia się na pełnym potoku przetwarzania danych. Obejmuje pobranie danych z API, zapisanie danych surowych, czyszczenie danych, tworzenie cech, obliczenie wyniku analitycznego, ewaluację oraz wizualizację rezultatów.

2 Źródło danych

Głównym źródłem danych jest współdzielone Weather REST API. Projekt korzysta z endpointu batch, który pobiera ostatnie pomiary pogodowe dla stacji GDN 01.

- Base URL: `https://e6uw49pbah.execute-api.us-east-1.amazonaws.com/dev`
- Endpoint: batch weather endpoint dla stacji GDN 01 z limitem 100 pomiarów
- Metoda autoryzacji: Bearer token

Odpowiedź API zawiera pomiary pogodowe z następującymi polami:

- timestamp,
- station id,
- temperature,
- humidity,
- pressure,
- wind speed,
- wind direction,
- rain amount,
- cloud cover.

3 Architektura systemu

Zaimplementowana architektura odpowiada typowemu potokowi przetwarzania danych:

Weather REST API → dane surowe → czyszczenie danych → tworzenie cech → scoring
→ ewaluacja → wykresy

Projekt został podzielony na osobne moduły Pythona:

- ingest.py – pobiera dane pogodowe z REST API i zapisuje surowe dane w formacie JSON.
- process.py – wczytuje dane surowe, sprawdza kolumny, czyści rekordy, usuwa duplikaty i zapisuje czysty zbiór danych.
- features.py – tworzy cechy kroczące i opóźnione wykorzystywane w analizie ryzyka deszczu.
- scoring.py – oblicza wynik ryzyka deszczu i przypisuje klasy ryzyka.
- evaluate.py – ocenia wyniki predykcji za pomocą metryk klasyfikacyjnych i generuje wykresy.
- main.py – uruchamia cały potok od pobrania danych do ewaluacji.

4 Struktura przechowywania danych

Projekt wykorzystuje lokalną strukturę plików podzieloną na warstwę danych surowych, przetworzonych i wynikowych.

```
data/
|-- raw/
|   |-- weather_raw.json
|
|-- processed/
|   |-- weather_clean.csv
|   |-- weather_features.csv
|
|-- output/
|   |-- rain_risk_scored.csv
|   |-- evaluation_metrics.txt
|   |-- rain_risk_chart.png
|   |-- confusion_matrix.png
```

Taka struktura oddziela dane surowe pobrane z API od danych wyczyszczonych, cech analitycznych oraz końcowych wyników projektu.

5 Czyszczenie danych

Etap czyszczenia danych przekształca surową odpowiedź API w uporządkowany zbiór tabelaryczny. Wykonywane są następujące operacje:

- parsowanie znaczników czasu do formatu daty i czasu,
- konwersja kolumn liczbowych do typów numerycznych,
- usunięcie rekordów bez znacznika czasu lub identyfikatora stacji,
- usunięcie duplikatów,
- sortowanie rekordów według stacji i czasu,
- ograniczenie wartości wilgotności i zachmurzenia do zakresu 0–100,
- zabezpieczenie przed ujemnymi wartościami opadu i prędkości wiatru.

Po czyszczeniu zbiór danych zawierał 100 rekordów.

6 Tworzenie cech

Tworzenie cech polega na przygotowaniu dodatkowych zmiennych na podstawie ostatnich pomiarów pogodowych. Cechy te opisują krótkoterminowe trendy pogodowe i są używane jako wejście do modelu oceny ryzyka deszczu.

W projekcie utworzono następujące cechy:

Cecha	Opis
Średnia krocząca wilgotności	Średnia wilgotność z 3 ostatnich pomiarów.
Średnia krocząca zachmurzenia	Średnie zachmurzenie z 3 ostatnich pomiarów.
Średnia krocząca prędkości wiatru	Średnia prędkość wiatru z 3 ostatnich pomiarów.
Suma niedawnych opadów	Suma opadów z 3 ostatnich pomiarów.
Zmiana ciśnienia	Różnica między bieżącą a poprzednią wartością ciśnienia.
Poprzedni opad	Wielkość opadu z poprzedniego pomiaru.
Czy spadnie deszcz	Binarna zmienna docelowa wskazująca, czy w następnym pomiarze wystąpi opad deszczu.

Tabela 1: Wygenerowane cechy

Po etapie tworzenia cech zbiór danych zawierał 98 rekordów, ponieważ część rekordów nie mogła zostać użyta do cech opóźnionych i predykcji kolejnego pomiaru.

7 Metody analityczne

W projekcie wykorzystano trzy główne metody analityczne: klasyfikację binarną, reguły model bazowy oraz ewaluację za pomocą precision i recall.

7.1 Klasyfikacja binarna

Zadanie predykcyjne zostało sformułowane jako problem klasyfikacji binarnej. Zmienna docelowa ma dwie możliwe wartości:

- 0 – deszcz nie wystąpi w kolejnym pomiarze,
- 1 – deszcz wystąpi w kolejnym pomiarze.

Zmienna binarna jest tworzona poprzez sprawdzenie, czy deszcz występuje w kolejnym pomiarze. Dzięki temu projekt realizuje krótkoterminową predykcję deszczu.

7.2 Reguły model bazowy

Reguły model bazowy oblicza wynik ryzyka deszczu w skali od 0 do 100. Wynik opiera się na zmiennych pogodowych, które są logicznie powiązane z ryzykiem deszczu: wilgotności, zachmurzeniu, spadku ciśnienia, poprzednim opadzie i prędkości wiatru.

Wagi wykorzystane w systemie scoringowym są następujące:

Zmienna	Waga
Wilgotność	30 procent
Zachmurzenie	25 procent
Spadek ciśnienia	20 procent
Poprzedni opad	15 procent
Prędkość wiatru	10 procent

Tabela 2: Wagi wskaźnika ryzyka opadów

Końcowy wynik ryzyka deszczu jest liczony według wzoru:

$$R = 0.30H + 0.25C + 0.20P + 0.15D + 0.10W$$

gdzie:

- R oznacza końcowy wynik ryzyka deszczu,
- H oznacza wynik wilgotności,
- C oznacza wynik zachmurzenia,
- P oznacza wynik spadku ciśnienia,
- D oznacza wynik poprzedniego opadu,
- W oznacza wynik prędkości wiatru.

Następnie wynik jest przekształcany na klasę ryzyka:

- 0–33: niskie ryzyko,
- 34–66: średnie ryzyko,
- 67–100: wysokie ryzyko.

System przewiduje deszcz, gdy wynik ryzyka deszczu jest większy lub równy 60.

7.3 Ewaluacja precision i recall

Jakość predykcji została oceniona za pomocą standardowych metryk klasyfikacyjnych:

- accuracy,
- precision,
- recall,
- F1-score,
- macierz pomyłek.

Precision określa, jak często system miał rację, gdy przewidział deszcz. Recall określa, jak wiele rzeczywistych przypadków deszczu zostało wykrytych przez system.

8 Wyniki

Potok przetwarzania został uruchomiony poprawnie. Program pobrał dane pogodowe, przetworzył zbiór danych, obliczył wyniki ryzyka deszczu, wygenerował predykcje oraz ocenił rezultaty.

Uzyskane metryki ewaluacyjne były następujące:

Metryka	Wartość
Accuracy	0.3571
Precision	0.5833
Recall	0.2090
F1-score	0.3077

Tabela 3: Metryki ewaluacyjne

Wartość precision równa 0.5833 oznacza, że gdy system przewidywał deszcz, miał rację w około 58 procentach przypadków. Wartość recall równa 0.2090 oznacza, że system wykrył około 21 procent wszystkich rzeczywistych przypadków deszczu.


Oznacza to, że model regułowy jest dość konserwatywny. Nie przewiduje deszczu bardzo często, ale gdy już to robi, jego predykcja jest poprawna w ponad połowie przypadków.

9 Wykresy

Projekt generuje dwa wyniki wizualne: wykres wyniku ryzyka deszczu w czasie oraz macierz pomyłek dla klasyfikacji binarnej.

9.1 Wynik ryzyka deszczu w czasie


Pierwszy wykres przedstawia wynik ryzyka deszczu w czasie. Zawiera również próg predykcji równy 60.



Rysunek 1: Wynik ryzyka deszczu w czasie

9.2 Macierz pomyłek

Drugi wykres przedstawia macierz pomyłek dla binarnej predykcji deszczu.



Rysunek 2: Macierz pomyłek dla predykcji deszczu

10 Wnioski

Projekt poprawnie implementuje pełny potok przetwarzania danych dla krótkoterminowej predykcji ryzyka deszczu. System pobiera dane z REST API, zapisuje surową odpowiedź,

czyści zbiór danych, tworzy cechy kroczące, oblicza regułowy wynik ryzyka deszczu oraz ocenia jakość predykcji.

Zaimplementowany model osiągnął precision na poziomie 0.5833 oraz recall na poziomie 0.2090. Oznacza to, że model lepiej radzi sobie z unikaniem fałszywych predykcji deszczu niż z wykrywaniem wszystkich rzeczywistych przypadków deszczu. Stosunkowo niska wartość recall pokazuje, że wiele rzeczywistych przypadków opadu nie zostało wykrytych.